Первые эксперименты по обучению nanoGPT со спарсными активациями

Цель на этом этапе — получить осмысленный первый экспериментальный артефакт с измеримыми результатами.

Сделали следующее:

1. подготовили маленький датасет для посимвольного языкового моделирования,
2. обучили dense-бейзлайн трансформера,
3. обучили sparse-вариант, где в FFN активны только top-k каналов,
4. сравнили сравнение в более тяжелой конфигурации с длинным контекстом,
5. сравнили loss, throughput и потребление памяти.

Постановка эксперимента

In [1]:
```
import time
from pathlib import Path

import matplotlib.pyplot as plt
import pandas as pd
import requests
import torch
import torch.nn as nn
import torch.nn.functional as F
from tqdm.auto import tqdm

device = 'cuda' if torch.cuda.is_available() else 'cpu'
torch.manual_seed(42)
device
```

Out[1]:
```
'cuda'
```

Данные

Для первых экспериментов используется корпус Tiny Shakespeare. Это стандартный достаточно большой датасет для быстрых экспериментов по языковому моделированию

In [2]:
```
data_dir = Path('data')
data_dir.mkdir(exist_ok=True)
text_path = data_dir / 'tiny_shakespeare.txt'

if not text_path.exists():
    text = requests.get('https://raw.githubusercontent.com/karpathy/char-rnn/master/data/tinys
    text_path.write_text(text)

text = text_path.read_text()
chars = sorted(list(set(text)))
stoi = {ch: i for i, ch in enumerate(chars)}
itos = {i: ch for ch, i in stoi.items()}
encode = lambda s: [stoi[c] for c in s]
decode = lambda ids: ''.join(itos[i] for i in ids)

data = torch.tensor(encode(text), dtype=torch.long)
split = int(0.9 * len(data))
train_data = data[:split]
val_data = data[split:]

len(text), len(chars), train_data.shape, val_data.shape
```

Out[2]:
```
(1115394, 65, torch.Size([1003854]), torch.Size([111540]))
```

Семейство моделей

В качестве бейзлайна используем компактный GPT-подобный трансформер. Sparse-вариант отличается только FFN-блоком: после первой линейной проекции для каждого токена активными остаются только top-k каналов по модулю активации. Это простое первое приближение к спарсификации активаций. Реализация специально сделана через dense-операции PyTorch, чтобы на первом этапе отделить эффект самой идеи от kernel-level оптимизации.

In [3]:
```
dropout = 0.1
vocab_size = len(chars)
ffn_mult = 4
sparsity_ratio = 0.75

class CausalSelfAttention(nn.Module):
    def __init__(self, n_embd, n_head):
        super().__init__()
        self.n_head = n_head
        self.head_dim = n_embd // n_head
        self.qkv = nn.Linear(n_embd, 3 * n_embd)
        self.proj = nn.Linear(n_embd, n_embd)
        self.resid_dropout = nn.Dropout(dropout)

    def forward(self, x):
        B, T, C = x.shape
        q, k, v = self.qkv(x).chunk(3, dim=-1)
        q = q.view(B, T, self.n_head, self.head_dim).transpose(1, 2)
        k = k.view(B, T, self.n_head, self.head_dim).transpose(1, 2)
        v = v.view(B, T, self.n_head, self.head_dim).transpose(1, 2)
        y = F.scaled_dot_product_attention(q, k, v, is_causal=True, dropout_p=dropout if self.
        y = y.transpose(1, 2).contiguous().view(B, T, C)
        y = self.resid_dropout(self.proj(y))
        return y

class DenseMLP(nn.Module):
    def __init__(self, n_embd):
        super().__init__()
        hidden = ffn_mult * n_embd
        self.fc = nn.Linear(n_embd, hidden)
        self.proj = nn.Linear(hidden, n_embd)
        self.dropout = nn.Dropout(dropout)

    def forward(self, x):
        x = self.fc(x)
        x = F.gelu(x)
        x = self.proj(x)
        x = self.dropout(x)
        return x

class SparseMLP(nn.Module):
    def __init__(self, n_embd, sparsity_ratio):
        super().__init__()
        hidden = ffn_mult * n_embd
        self.keep = max(1, int(hidden * (1 - sparsity_ratio)))
        self.fc = nn.Linear(n_embd, hidden)
        self.proj = nn.Linear(hidden, n_embd)
        self.dropout = nn.Dropout(dropout)

    def forward(self, x):
        x = self.fc(x)
        x = F.gelu(x)
        _, indices = torch.topk(x.abs(), k=self.keep, dim=-1)
        mask = torch.zeros_like(x)
        mask.scatter_(-1, indices, 1.0)
        x = x * mask
        x = self.proj(x)
        x = self.dropout(x)
        return x

class Block(nn.Module):
    def __init__(self, n_embd, n_head, sparse=False, sparsity_ratio=0.0):
```

```
        super().__init__()
        self.ln1 = nn.LayerNorm(n_embd)
        self.attn = CausalSelfAttention(n_embd, n_head)
        self.ln2 = nn.LayerNorm(n_embd)
        self.mlp = SparseMLP(n_embd, sparsity_ratio) if sparse else DenseMLP(n_embd)

    def forward(self, x):
        x = x + self.attn(self.ln1(x))
        x = x + self.mlp(self.ln2(x))
        return x

class TinyGPT(nn.Module):
    def __init__(self, block_size, n_embd, n_head, n_layer, sparse=False, sparsity_ratio=0.0):
        super().__init__()
        self.token_emb = nn.Embedding(vocab_size, n_embd)
        self.pos_emb = nn.Embedding(block_size, n_embd)
        self.blocks = nn.ModuleList([Block(n_embd, n_head, sparse=sparse, sparsity_ratio=spars
        self.ln_f = nn.LayerNorm(n_embd)
        self.head = nn.Linear(n_embd, vocab_size, bias=False)

    def forward(self, idx, targets=None):
        B, T = idx.shape
        pos = torch.arange(T, device=idx.device)
        x = self.token_emb(idx) + self.pos_emb(pos)[None, :, :]
        for block in self.blocks:
            x = block(x)
        x = self.ln_f(x)
        logits = self.head(x)
        loss = None
        if targets is not None:
            loss = F.cross_entropy(logits.view(-1, logits.size(-1)), targets.view(-1))
        return logits, loss
```

Эксперимент 1: short-context бейзлайн

Первое сравнение проверяет, остается ли sparse-приближение вообще обучаемым в умеренной конфигурации

In [4]:
```
experiment_name = 'short_context'
batch_size = 32
block_size = 128
n_embd = 192
n_head = 6
n_layer = 4
steps = 120
eval_interval = 20
lr = 3e-4

results = []

for name, sparse_flag in [('dense', False), ('sparse', True)]:
    model = TinyGPT(block_size=block_size, n_embd=n_embd, n_head=n_head, n_layer=n_layer, spar
    optimizer = torch.optim.AdamW(model.parameters(), lr=lr)
    if device == 'cuda':
        torch.cuda.reset_peak_memory_stats()
        torch.cuda.synchronize()
    start = time.time()
    progress = tqdm(range(1, steps + 1), desc=f'{experiment_name}:{name}', leave=False)
    for step in progress:
        ix = torch.randint(len(train_data) - block_size - 1, (batch_size,))
        xb = torch.stack([train_data[i:i + block_size] for i in ix]).to(device)
        yb = torch.stack([train_data[i + 1:i + block_size + 1] for i in ix]).to(device)
        model.train()
        optimizer.zero_grad(set_to_none=True)
        _, loss = model(xb, yb)
        loss.backward()
        optimizer.step()

        if step % eval_interval == 0 or step == 1:
            model.eval()
            with torch.no_grad():
                ix_val = torch.randint(len(val_data) - block_size - 1, (batch_size,))
```

```
                xval = torch.stack([val_data[i:i + block_size] for i in ix_val]).to(device)
                yval = torch.stack([val_data[i + 1:i + block_size + 1] for i in ix_val]).to(de
                _, val_loss = model(xval, yval)
            progress.set_postfix(train_loss=f'{loss.item():.3f}', val_loss=f'{val_loss.item():
            results.append({
                'experiment': experiment_name,
                'model': name,
                'step': step,
                'train_loss': loss.item(),
                'val_loss': val_loss.item()
            })
    if device == 'cuda':
        torch.cuda.synchronize()
    elapsed = time.time() - start
    peak_memory_mb = torch.cuda.max_memory_allocated() / 1024**2 if device == 'cuda' else floa
    tokens_processed = steps * batch_size * block_size
    results.append({
        'experiment': experiment_name,
        'model': name,
        'step': 'summary',
        'train_loss': float('nan'),
        'val_loss': float('nan'),
        'elapsed_sec': elapsed,
        'tokens_per_sec': tokens_processed / elapsed,
        'peak_memory_mb': peak_memory_mb
    })

results_df = pd.DataFrame(results)
results_df
```

```
short_context:dense:   0%|          | 0/120 [00:00<?, ?it/s]
short_context:sparse:   0%|          | 0/120 [00:00<?, ?it/s]
```

Out[4]:

	experiment	model	step	train_loss	val_loss	elapsed_sec	tokens_per_sec	peak_memory_mb
0	short_context	dense	1	4.301603	4.095449	NaN	NaN	NaN
1	short_context	dense	20	3.019353	3.066434	NaN	NaN	NaN
2	short_context	dense	40	2.805069	2.728816	NaN	NaN	NaN
3	short_context	dense	60	2.688743	2.625922	NaN	NaN	NaN
4	short_context	dense	80	2.578394	2.594366	NaN	NaN	NaN
5	short_context	dense	100	2.562107	2.571986	NaN	NaN	NaN
6	short_context	dense	120	2.568209	2.561136	NaN	NaN	NaN
7	short_context	dense	summary	NaN	NaN	3.599376	136557.013655	262.684570
8	short_context	sparse	1	4.352662	4.144049	NaN	NaN	NaN
9	short_context	sparse	20	3.073329	3.125726	NaN	NaN	NaN
10	short_context	sparse	40	2.794577	2.830472	NaN	NaN	NaN
11	short_context	sparse	60	2.672176	2.661069	NaN	NaN	NaN
12	short_context	sparse	80	2.594256	2.629147	NaN	NaN	NaN
13	short_context	sparse	100	2.532334	2.610502	NaN	NaN	NaN
14	short_context	sparse	120	2.563842	2.528488	NaN	NaN	NaN
15	short_context	sparse	summary	NaN	NaN	3.896818	126133.683884	314.820312

Результат short-context эксперимента уже сам по себе осмысленный. Обе модели обучаются стабильно и сходятся к очень близкому значению validation loss. Dense-бейзлайн заканчивает с validation loss около 2.56, а sparse-вариант достигает примерно 2.53. При этом sparse PyTorch-прокси уже на этой легкой конфигурации остается менее эффективным: throughput падает примерно со 136.6k до 126.1k tokens/sec, а peak memory растет примерно с 262.7 MB до 314.8 MB. Это нормально для dense-backed реализации через torch. Именно этот разрыв и мотивирует следующий этап проекта со специализированными kernels.

Эксперимент 2: более тяжелая longer-context конфигурация

Сравнение повторяется в более тяжелой конфигурации с большим контекстом, большим hidden size и большим числом слоев. Проверим, сохраняется ли тот же качественный паттерн в заметно более тяжелом режиме обучения.

In [5]:
```
experiment_name = 'longer_context'
batch_size = 24
block_size = 256
n_embd = 256
n_head = 8
n_layer = 6
steps = 160
eval_interval = 20
lr = 3e-4

for name, sparse_flag in [('dense', False), ('sparse', True)]:
    model = TinyGPT(block_size=block_size, n_embd=n_embd, n_head=n_head, n_layer=n_layer, spar
    optimizer = torch.optim.AdamW(model.parameters(), lr=lr)
    if device == 'cuda':
        torch.cuda.reset_peak_memory_stats()
        torch.cuda.synchronize()
    start = time.time()
    progress = tqdm(range(1, steps + 1), desc=f'{experiment_name}:{name}', leave=False)
    for step in progress:
        ix = torch.randint(len(train_data) - block_size - 1, (batch_size,))
        xb = torch.stack([train_data[i:i + block_size] for i in ix]).to(device)
        yb = torch.stack([train_data[i + 1:i + block_size + 1] for i in ix]).to(device)
        model.train()
        optimizer.zero_grad(set_to_none=True)
        _, loss = model(xb, yb)
        loss.backward()
        optimizer.step()

        if step % eval_interval == 0 or step == 1:
            model.eval()
            with torch.no_grad():
                ix_val = torch.randint(len(val_data) - block_size - 1, (batch_size,))
                xval = torch.stack([val_data[i:i + block_size] for i in ix_val]).to(device)
                yval = torch.stack([val_data[i + 1:i + block_size + 1] for i in ix_val]).to(de
                _, val_loss = model(xval, yval)
            progress.set_postfix(train_loss=f'{loss.item():.3f}', val_loss=f'{val_loss.item():
            results.append({
                'experiment': experiment_name,
                'model': name,
                'step': step,
                'train_loss': loss.item(),
                'val_loss': val_loss.item()
            })
    if device == 'cuda':
        torch.cuda.synchronize()
    elapsed = time.time() - start
    peak_memory_mb = torch.cuda.max_memory_allocated() / 1024**2 if device == 'cuda' else floa
    tokens_processed = steps * batch_size * block_size
    results.append({
        'experiment': experiment_name,
        'model': name,
        'step': 'summary',
        'train_loss': float('nan'),
        'val_loss': float('nan'),
        'elapsed_sec': elapsed,
        'tokens_per_sec': tokens_processed / elapsed,
        'peak_memory_mb': peak_memory_mb
    })

results_df = pd.DataFrame(results)
results_df
```

```
longer_context:dense:   0%|          | 0/160 [00:00<?, ?it/s]
longer_context:sparse:   0%|          | 0/160 [00:00<?, ?it/s]
```

Out[5]:

	experiment	model	step	train_loss	val_loss	elapsed_sec	tokens_per_sec	peak_memory_ml
0	short_context	dense	1	4.301603	4.095449	NaN	NaN	NaN
1	short_context	dense	20	3.019353	3.066434	NaN	NaN	NaN
2	short_context	dense	40	2.805069	2.728816	NaN	NaN	NaN
3	short_context	dense	60	2.688743	2.625922	NaN	NaN	NaN
4	short_context	dense	80	2.578394	2.594366	NaN	NaN	NaN
5	short_context	dense	100	2.562107	2.571986	NaN	NaN	NaN
6	short_context	dense	120	2.568209	2.561136	NaN	NaN	NaN
7	short_context	dense	summary	NaN	NaN	3.599376	136557.013655	262.68457
8	short_context	sparse	1	4.352662	4.144049	NaN	NaN	NaN
9	short_context	sparse	20	3.073329	3.125726	NaN	NaN	NaN
10	short_context	sparse	40	2.794577	2.830472	NaN	NaN	NaN
11	short_context	sparse	60	2.672176	2.661069	NaN	NaN	NaN
12	short_context	sparse	80	2.594256	2.629147	NaN	NaN	NaN
13	short_context	sparse	100	2.532334	2.610502	NaN	NaN	NaN
14	short_context	sparse	120	2.563842	2.528488	NaN	NaN	NaN
15	short_context	sparse	summary	NaN	NaN	3.896818	126133.683884	314.82031
16	longer_context	dense	1	4.270689	3.867939	NaN	NaN	NaN
17	longer_context	dense	20	2.800681	2.785463	NaN	NaN	NaN
18	longer_context	dense	40	2.654001	2.657590	NaN	NaN	NaN
19	longer_context	dense	60	2.553866	2.531372	NaN	NaN	NaN
20	longer_context	dense	80	2.535877	2.510544	NaN	NaN	NaN
21	longer_context	dense	100	2.535131	2.460968	NaN	NaN	NaN
22	longer_context	dense	120	2.515924	2.508768	NaN	NaN	NaN
23	longer_context	dense	140	2.486244	2.508986	NaN	NaN	NaN
24	longer_context	dense	160	2.482704	2.491071	NaN	NaN	NaN
25	longer_context	dense	summary	NaN	NaN	12.460939	78889.718332	721.56054
26	longer_context	sparse	1	4.321991	3.934633	NaN	NaN	NaN
27	longer_context	sparse	20	2.951446	2.898590	NaN	NaN	NaN
28	longer_context	sparse	40	2.667506	2.711812	NaN	NaN	NaN
29	longer_context	sparse	60	2.588620	2.589536	NaN	NaN	NaN
30	longer_context	sparse	80	2.547042	2.523695	NaN	NaN	NaN
31	longer_context	sparse	100	2.493126	2.519104	NaN	NaN	NaN
32	longer_context	sparse	120	2.516619	2.497406	NaN	NaN	NaN
33	longer_context	sparse	140	2.485936	2.500726	NaN	NaN	NaN
34	longer_context	sparse	160	2.492380	2.468891	NaN	NaN	NaN
35	longer_context	sparse	summary	NaN	NaN	16.084497	61117.236152	872.99316

Графики обучения

In [6]:

```
curve_df = results_df[results_df['step'] != 'summary'].copy()
curve_df['step'] = curve_df['step'].astype(int)

fig, axes = plt.subplots(1, 2, figsize=(14, 4))
for experiment in curve_df['experiment'].unique():
```

```
    subset = curve_df[curve_df['experiment'] == experiment]
    for model_name in subset['model'].unique():
        part = subset[subset['model'] == model_name]
        axes[0].plot(part['step'], part['train_loss'], marker='o', label=f'{experiment}-{model
        axes[1].plot(part['step'], part['val_loss'], marker='o', label=f'{experiment}-{model_n
axes[0].set_title('Train loss')
axes[1].set_title('Validation loss')
axes[0].set_xlabel('Step')
axes[1].set_xlabel('Step')
axes[0].legend()
axes[1].legend()
plt.tight_layout()
plt.show()
```

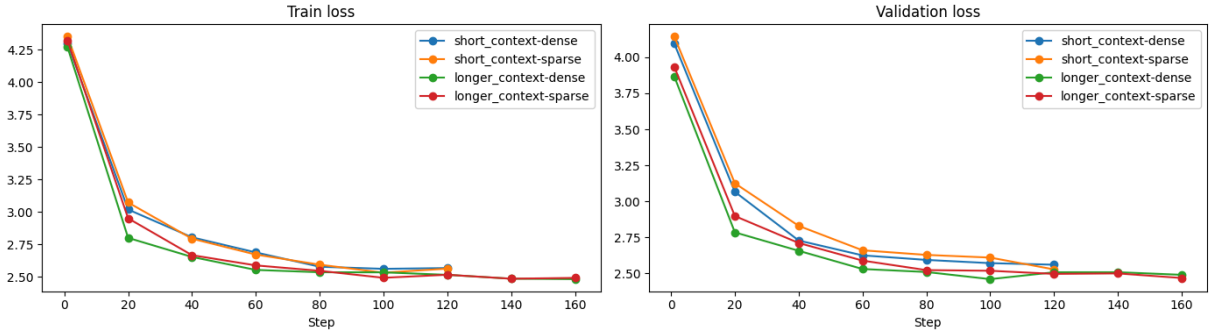

Первый вопрос состоит в том, остается ли sparse-вариант обучаемым и в легкой, и в более тяжелой конфигурации. По кривым видно, что ответ положительный: в short-context эксперименте dense-модель заканчивает с validation loss около 2.56, а sparse-модель около 2.53; в longer-context эксперименте dense-модель заканчивает около 2.49, а sparse-модель около 2.47. То есть даже в более тяжелом режиме sparse-вариант не ломает оптимизацию и приходит к сопоставимому, а местами даже чуть лучшему качеству.

Сравнение эффективности

In [7]:
```
summary_df = results_df[results_df['step'] == 'summary'][['experiment', 'model', 'elapsed_sec'
summary_df
```

Out[7]:

	experiment	model	elapsed_sec	tokens_per_sec	peak_memory_mb
0	short_context	dense	3.599376	136557.013655	262.684570
1	short_context	sparse	3.896818	126133.683884	314.820312
2	longer_context	dense	12.460939	78889.718332	721.560547
3	longer_context	sparse	16.084497	61117.236152	872.993164

In [8]:
```
fig, axes = plt.subplots(1, 2, figsize=(12, 4))
throughput_pivot = summary_df.pivot(index='experiment', columns='model', values='tokens_per_se
memory_pivot = summary_df.pivot(index='experiment', columns='model', values='peak_memory_mb')
throughput_pivot.plot(kind='bar', ax=axes[0], rot=0, title='Throughput')
axes[0].set_ylabel('Tokens/sec')
memory_pivot.plot(kind='bar', ax=axes[1], rot=0, title='Peak memory')
axes[1].set_ylabel('MB')
plt.tight_layout()
plt.show()
```

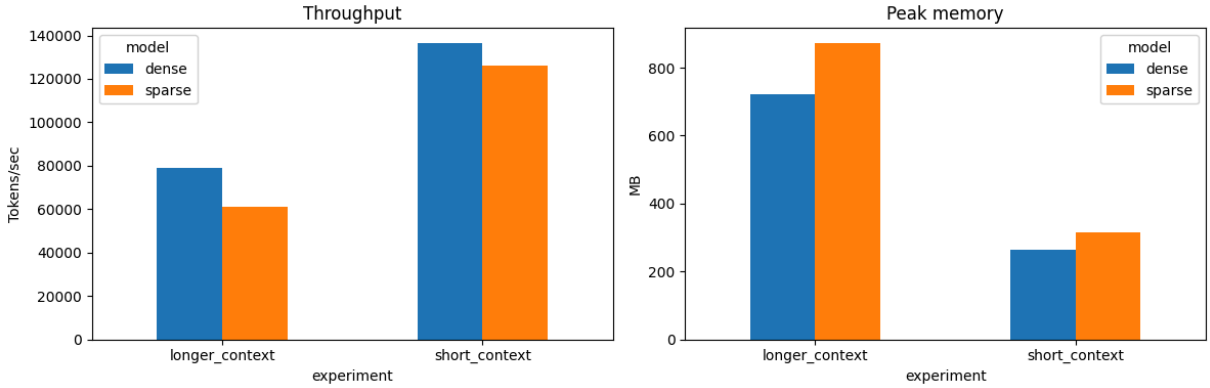

Второй вопрос состоит в том, меняет ли спарсификация время работы и потребление памяти еще до появления кастомных kernels. Ответ по результатам первого этапа тоже однозначный: при vanilla PyTorch masking спарсификация делает обучение и медленнее, и тяжелее по памяти в обеих конфигурациях. В short-context режиме throughput падает примерно со 136.6k до 126.1k tokens/sec, а peak memory растет с 262.7 MB до 314.8 MB. В longer-context режиме штраф становится еще заметнее: throughput падает примерно с 78.9k до 61.1k tokens/sec, а peak memory растет с 721.6 MB до 873.0 MB. Таким образо, мы отделяем идею спарсификации от системной эффективности и задаем конкретную цель для будущей kernel-оптимизации.

Эксперимент 3: Абляция по уровню спарсности

Проверим, как качество и эффективность зависят от значения `sparsity_ratio`. Запустим несколько sparse-вариантов с уровнями 0.25, 0.5, 0.75 и 0.9 на базе short-context конфигурации.

In [9]:
```
experiment_name = 'sparsity_ablation'
batch_size = 32
block_size = 128
n_embd = 192
n_head = 6
n_layer = 4
steps = 120
eval_interval = 20
lr = 3e-4

sparsity_ratios = [0.25, 0.5, 0.75, 0.9]
results_sparsity = []

for ratio in sparsity_ratios:
    name = f'sparse_{ratio}'
    model = TinyGPT(block_size=block_size, n_embd=n_embd, n_head=n_head, n_layer=n_layer, spar
    optimizer = torch.optim.AdamW(model.parameters(), lr=lr)
    if device == 'cuda':
        torch.cuda.reset_peak_memory_stats()
        torch.cuda.synchronize()
    start = time.time()
    progress = tqdm(range(1, steps + 1), desc=f'{experiment_name}:{name}', leave=False)
    for step in progress:
        ix = torch.randint(len(train_data) - block_size - 1, (batch_size,))
        xb = torch.stack([train_data[i:i + block_size] for i in ix]).to(device)
        yb = torch.stack([train_data[i + 1:i + block_size + 1] for i in ix]).to(device)
        model.train()
        optimizer.zero_grad(set_to_none=True)
        _, loss = model(xb, yb)
        loss.backward()
        optimizer.step()

        if step % eval_interval == 0 or step == 1:
            model.eval()
            with torch.no_grad():
                ix_val = torch.randint(len(val_data) - block_size - 1, (batch_size,))
                xval = torch.stack([val_data[i:i + block_size] for i in ix_val]).to(device)
                yval = torch.stack([val_data[i + 1:i + block_size + 1] for i in ix_val]).to(de
                _, val_loss = model(xval, yval)
            progress.set_postfix(train_loss=f'{loss.item():.3f}', val_loss=f'{val_loss.item():
```

```
            results_sparsity.append({
                'experiment': experiment_name,
                'model': name,
                'step': step,
                'train_loss': loss.item(),
                'val_loss': val_loss.item()
            })
    if device == 'cuda':
        torch.cuda.synchronize()
    elapsed = time.time() - start
    peak_memory_mb = torch.cuda.max_memory_allocated() / 1024**2 if device == 'cuda' else floa
    tokens_processed = steps * batch_size * block_size
    results_sparsity.append({
        'experiment': experiment_name,
        'model': name,
        'step': 'summary',
        'train_loss': float('nan'),
        'val_loss': float('nan'),
        'elapsed_sec': elapsed,
        'tokens_per_sec': tokens_processed / elapsed,
        'peak_memory_mb': peak_memory_mb
    })

results_sparsity_df = pd.DataFrame(results_sparsity)
results_sparsity_df[results_sparsity_df['step'] == 'summary']
```

```
sparsity_ablation:sparse_0.25:   0%|          | 0/120 [00:00<?, ?it/s]
sparsity_ablation:sparse_0.5:   0%|          | 0/120 [00:00<?, ?it/s]
sparsity_ablation:sparse_0.75:   0%|          | 0/120 [00:00<?, ?it/s]
sparsity_ablation:sparse_0.9:   0%|          | 0/120 [00:00<?, ?it/s]
```

Out[9]:

	experiment	model	step	train_loss	val_loss	elapsed_sec	tokens_per_sec	peak_memo
7	sparsity_ablation	sparse_0.25	summary	NaN	NaN	4.139915	118727.082454	354.4
15	sparsity_ablation	sparse_0.5	summary	NaN	NaN	3.971007	123777.164469	322.8
23	sparsity_ablation	sparse_0.75	summary	NaN	NaN	3.921188	125349.755116	313.8
31	sparsity_ablation	sparse_0.9	summary	NaN	NaN	3.645028	134846.705357	310.6

In [10]:

```
curve_df = results_sparsity_df[results_sparsity_df['step'] != 'summary'].copy()
curve_df['step'] = curve_df['step'].astype(int)

fig, axes = plt.subplots(1, 2, figsize=(14, 4))
for model_name in curve_df['model'].unique():
    part = curve_df[curve_df['model'] == model_name]
    axes[0].plot(part['step'], part['train_loss'], marker='o', label=model_name)
    axes[1].plot(part['step'], part['val_loss'], marker='o', label=model_name)
axes[0].set_title('Train loss (Sparsity Ablation)')
axes[1].set_title('Validation loss (Sparsity Ablation)')
axes[0].set_xlabel('Step')
axes[1].set_xlabel('Step')
axes[0].legend()
axes[1].legend()
plt.tight_layout()
plt.show()
```

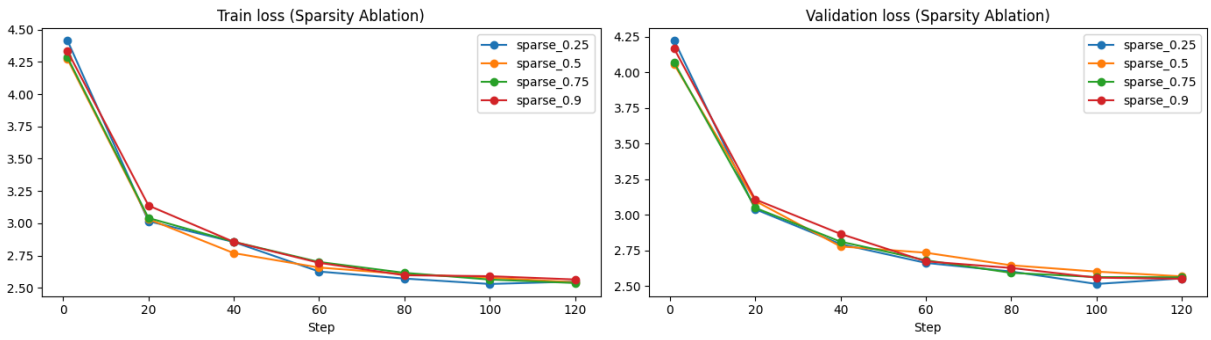

Эксперимент 4: Масштабирование по длине контекста

Проверим несколько значений `block_size` (128, 256, 512), чтобы посмотреть, как растет потребление памяти и сохраняется ли обучаемость sparse-варианта на более длинном контексте.

In [11]:
```
experiment_name = 'block_size_scaling'
batch_size = 16
block_sizes = [128, 256, 512]
n_embd = 192
n_head = 6
n_layer = 4
steps = 120
eval_interval = 20
lr = 3e-4
sparsity_ratio = 0.75

results_context = []

for b_size in block_sizes:
    for name, sparse_flag in [('dense', False), ('sparse', True)]:
        model_name = f'{name}_{b_size}'
        model = TinyGPT(block_size=b_size, n_embd=n_embd, n_head=n_head, n_layer=n_layer, spar
        optimizer = torch.optim.AdamW(model.parameters(), lr=lr)
        if device == 'cuda':
            torch.cuda.reset_peak_memory_stats()
            torch.cuda.synchronize()
        start = time.time()
        progress = tqdm(range(1, steps + 1), desc=f'{experiment_name}:{model_name}', leave=Fal
        for step in progress:
            ix = torch.randint(len(train_data) - b_size - 1, (batch_size,))
            xb = torch.stack([train_data[i:i + b_size] for i in ix]).to(device)
            yb = torch.stack([train_data[i + 1:i + b_size + 1] for i in ix]).to(device)
            model.train()
            optimizer.zero_grad(set_to_none=True)
            _, loss = model(xb, yb)
            loss.backward()
            optimizer.step()

            if step % eval_interval == 0 or step == 1:
                model.eval()
                with torch.no_grad():
                    ix_val = torch.randint(len(val_data) - b_size - 1, (batch_size,))
                    xval = torch.stack([val_data[i:i + b_size] for i in ix_val]).to(device)
                    yval = torch.stack([val_data[i + 1:i + b_size + 1] for i in ix_val]).to(de
                    _, val_loss = model(xval, yval)
                progress.set_postfix(train_loss=f'{loss.item():.3f}', val_loss=f'{val_loss.ite
                results_context.append({
                    'experiment': experiment_name,
                    'model': model_name,
                    'block_size': b_size,
                    'is_sparse': sparse_flag,
                    'step': step,
                    'train_loss': loss.item(),
                    'val_loss': val_loss.item()
                })
        if device == 'cuda':
            torch.cuda.synchronize()
        elapsed = time.time() - start
        peak_memory_mb = torch.cuda.max_memory_allocated() / 1024**2 if device == 'cuda' else
        tokens_processed = steps * batch_size * b_size
        results_context.append({
            'experiment': experiment_name,
            'model': model_name,
            'block_size': b_size,
            'is_sparse': sparse_flag,
            'step': 'summary',
            'train_loss': float('nan'),
            'val_loss': float('nan'),
            'elapsed_sec': elapsed,
            'tokens_per_sec': tokens_processed / elapsed,
            'peak_memory_mb': peak_memory_mb
        })

results_context_df = pd.DataFrame(results_context)
results_context_df[results_context_df['step'] == 'summary']
```

```
block_size_scaling:dense_128:   0%|          | 0/120 [00:00<?, ?it/s]
block_size_scaling:sparse_128:   0%|          | 0/120 [00:00<?, ?it/s]
block_size_scaling:dense_256:   0%|          | 0/120 [00:00<?, ?it/s]
block_size_scaling:sparse_256:   0%|          | 0/120 [00:00<?, ?it/s]
block_size_scaling:dense_512:   0%|          | 0/120 [00:00<?, ?it/s]
block_size_scaling:sparse_512:   0%|          | 0/120 [00:00<?, ?it/s]
```

Out[11]:

	experiment	model	block_size	is_sparse	step	train_loss	val_loss	elapsed_sec	toke
7	block_size_scaling	dense_128	128	False	summary	NaN	NaN	1.628425	15(
15	block_size_scaling	sparse_128	128	True	summary	NaN	NaN	2.120921	11!
23	block_size_scaling	dense_256	256	False	summary	NaN	NaN	3.108877	15!
31	block_size_scaling	sparse_256	256	True	summary	NaN	NaN	4.187752	117
39	block_size_scaling	dense_512	512	False	summary	NaN	NaN	7.063112	13!
47	block_size_scaling	sparse_512	512	True	summary	NaN	NaN	9.196479	106

In [12]:

```python
summary_ctx = results_context_df[results_context_df['step'] == 'summary'].copy()
summary_ctx['type'] = summary_ctx['is_sparse'].map({True: 'sparse', False: 'dense'})

fig, axes = plt.subplots(1, 2, figsize=(12, 4))
for mtype in ['dense', 'sparse']:
    part = summary_ctx[summary_ctx['type'] == mtype]
    axes[0].plot(part['block_size'], part['tokens_per_sec'], marker='o', label=mtype)
    axes[1].plot(part['block_size'], part['peak_memory_mb'], marker='o', label=mtype)
axes[0].set_title('Throughput vs Block Size')
axes[0].set_xlabel('Block Size')
axes[0].set_ylabel('Tokens/sec')
axes[0].legend()
axes[1].set_title('Peak Memory vs Block Size')
axes[1].set_xlabel('Block Size')
axes[1].set_ylabel('MB')
axes[1].legend()
plt.tight_layout()
plt.show()
```

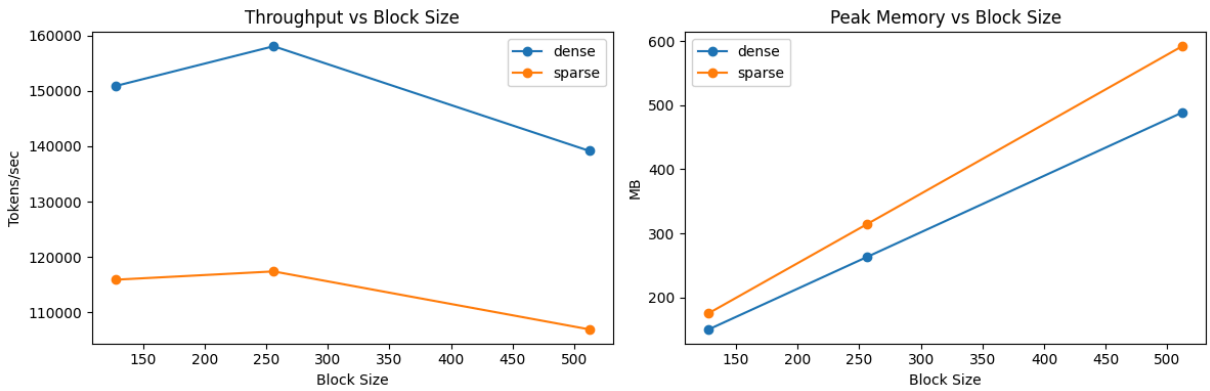

Эксперимент 5: Масштабирование по размеру модели

Сравним текущую конфигурацию с более крупными за счет увеличения `n_embd` и `n_layer`, чтобы оценить, как масштабируется цена sparse-прокси по времени и памяти.

In [13]:

```python
experiment_name = 'model_size_scaling'
batch_size = 16
block_size = 256
steps = 120
eval_interval = 20
lr = 3e-4
sparsity_ratio = 0.75

configs = [
    {'name': 'small', 'n_embd': 192, 'n_head': 6, 'n_layer': 4},
    {'name': 'medium', 'n_embd': 256, 'n_head': 8, 'n_layer': 6},
    {'name': 'large', 'n_embd': 384, 'n_head': 6, 'n_layer': 6}
]
```

```python
results_size = []

for config in configs:
    for name, sparse_flag in [('dense', False), ('sparse', True)]:
        model_name = f"{config['name']}_{name}"
        model = TinyGPT(block_size=block_size, n_embd=config['n_embd'], n_head=config['n_head'
        optimizer = torch.optim.AdamW(model.parameters(), lr=lr)
        if device == 'cuda':
            torch.cuda.reset_peak_memory_stats()
            torch.cuda.synchronize()
        start = time.time()
        progress = tqdm(range(1, steps + 1), desc=f'{experiment_name}:{model_name}', leave=Fal
        for step in progress:
            ix = torch.randint(len(train_data) - block_size - 1, (batch_size,))
            xb = torch.stack([train_data[i:i + block_size] for i in ix]).to(device)
            yb = torch.stack([train_data[i + 1:i + block_size + 1] for i in ix]).to(device)
            model.train()
            optimizer.zero_grad(set_to_none=True)
            _, loss = model(xb, yb)
            loss.backward()
            optimizer.step()

            if step % eval_interval == 0 or step == 1:
                model.eval()
                with torch.no_grad():
                    ix_val = torch.randint(len(val_data) - block_size - 1, (batch_size,))
                    xval = torch.stack([val_data[i:i + block_size] for i in ix_val]).to(device
                    yval = torch.stack([val_data[i + 1:i + block_size + 1] for i in ix_val]).t
                    _, val_loss = model(xval, yval)
                progress.set_postfix(train_loss=f'{loss.item():.3f}', val_loss=f'{val_loss.ite
                results_size.append({
                    'experiment': experiment_name,
                    'model': model_name,
                    'size_config': config['name'],
                    'is_sparse': sparse_flag,
                    'step': step,
                    'train_loss': loss.item(),
                    'val_loss': val_loss.item()
                })
        if device == 'cuda':
            torch.cuda.synchronize()
        elapsed = time.time() - start
        peak_memory_mb = torch.cuda.max_memory_allocated() / 1024**2 if device == 'cuda' else
        tokens_processed = steps * batch_size * block_size
        results_size.append({
            'experiment': experiment_name,
            'model': model_name,
            'size_config': config['name'],
            'is_sparse': sparse_flag,
            'step': 'summary',
            'train_loss': float('nan'),
            'val_loss': float('nan'),
            'elapsed_sec': elapsed,
            'tokens_per_sec': tokens_processed / elapsed,
            'peak_memory_mb': peak_memory_mb
        })

results_size_df = pd.DataFrame(results_size)
results_size_df[results_size_df['step'] == 'summary']
```

```
model_size_scaling:small_dense:   0%|          | 0/120 [00:00<?, ?it/s]
model_size_scaling:small_sparse:   0%|          | 0/120 [00:00<?, ?it/s]
model_size_scaling:medium_dense:   0%|          | 0/120 [00:00<?, ?it/s]
model_size_scaling:medium_sparse:   0%|          | 0/120 [00:00<?, ?it/s]
model_size_scaling:large_dense:   0%|          | 0/120 [00:00<?, ?it/s]
model_size_scaling:large_sparse:   0%|          | 0/120 [00:00<?, ?it/s]
```

Out[13]:

	experiment	model	size_config	is_sparse	step	train_loss	val_loss	elapsed_sec
7	model_size_scaling	small_dense	small	False	summary	NaN	NaN	3.221796
15	model_size_scaling	small_sparse	small	True	summary	NaN	NaN	4.217268
23	model_size_scaling	medium_dense	medium	False	summary	NaN	NaN	6.834300
31	model_size_scaling	medium_sparse	medium	True	summary	NaN	NaN	8.742708
39	model_size_scaling	large_dense	large	False	summary	NaN	NaN	12.692104
47	model_size_scaling	large_sparse	large	True	summary	NaN	NaN	14.963868

In [14]:

```
summary_size = results_size_df[results_size_df['step'] == 'summary'].copy()
summary_size['type'] = summary_size['is_sparse'].map({True: 'sparse', False: 'dense'})

fig, axes = plt.subplots(1, 2, figsize=(12, 4))
for mtype in ['dense', 'sparse']:
    part = summary_size[summary_size['type'] == mtype]
    axes[0].plot(part['size_config'], part['tokens_per_sec'], marker='o', label=mtype)
    axes[1].plot(part['size_config'], part['peak_memory_mb'], marker='o', label=mtype)
axes[0].set_title('Throughput vs Model Size')
axes[0].set_xlabel('Model Size')
axes[0].set_ylabel('Tokens/sec')
axes[0].legend()
axes[1].set_title('Peak Memory vs Model Size')
axes[1].set_xlabel('Model Size')
axes[1].set_ylabel('MB')
axes[1].legend()
plt.tight_layout()
plt.show()
```

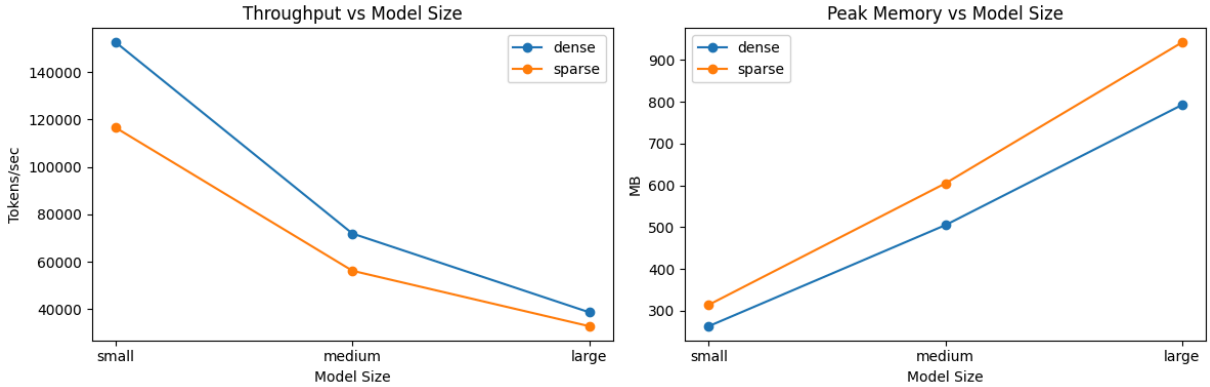

Вывод по абляциям

Проведенные абляции подтверждают, что спарсная модель остается обучаемой при разных уровнях спарсности, длинах контекста и размерах модели. При этом во всех случаях наблюдается системный оверхед от наивной PyTorch-реализации (падение throughput и рост peak memory). Это окончательно формирует мотивацию для следующего этапа: разработки кастомных Triton-ядер для эффективного вычисления sparse FFN.

Вывод по первым экспериментам

1. В коротком контексте dense- и sparse-модели обучаются очень похоже по качеству. Dense заканчивает примерно на validation loss 2.56, sparse — примерно на 2.53. Даже на наивной реализации через torch спарсификация не ломает обучение. Системно sparse уже хуже dense: throughput падает примерно с 136.6k до 126.1k tokens/sec, а peak memory растет примерно с 262.7 MB до 314.8 MB. Значит, сама идея модельно жизнеспособна, но текущая реализация вычислительно неэффективна.

2. В более тяжелой конфигурации картина сохраняется. Dense приходит примерно к validation loss 2.49, sparse — примерно к 2.47. То есть при увеличении нагрузки sparse-вариант все еще остается

обучаемым и не деградирует по качеству. Но системный штраф становится заметнее: throughput падает примерно с 78.9k до 61.1k tokens/sec, а peak memory растет примерно с 721.6 MB до 873.0 MB. Это особенно важно, потому что именно long-context режим изначально и был основной мотивацией проекта. Пока что наивная sparse-реализация не помогает, а мешает.

3. По графикам абляции видно, что в диапазоне примерно 0.25–0.9 модель остается обучаемой во всех протестированных режимах спарсности. Кривые train/validation loss идут близко друг к другу, а к концу различия между вариантами небольшие. Это означает, что top-k sparsification в FFN не является хрупкой идеей, работающей только в одной специально подобранной точке. Наоборот, есть целое семейство рабочих режимов. Дальше можно не спорить о том, работает ли сама идея, а переходить к вопросу, какой уровень спарсности дает лучший компромисс между качеством и стоимостью.

4. При росте длины контекста память растет у обеих моделей, что ожидаемо. Но sparse-вариант стабильно потребляет больше памяти, чем dense, и проигрывает по throughput на всех протестированных значениях `block_size`. В текущем виде sparse FFN не дает системного выигрыша даже там, где интуитивно хотелось бы его увидеть — при росте контекста. Следовательно, bottleneck находится не в самой идее sparsity, а в способе ее реализации через torch.

5. При увеличении размера модели dense и sparse обе продолжают масштабироваться по качеству нормально, но sparse снова стабильно проигрывает по скорости и памяти. Причем с ростом модели этот разрыв не исчезает, а остается устойчивым. Это означает, что проблема не локальна для одной маленькой конфигурации. Наоборот, текущая реализация имеет системный overhead, который переносится и на более крупные модели. Для защиты это очень хороший аргумент: показано, что проблема воспроизводится по нескольким осям масштабирования — по контексту, по размеру модели и по уровню спарсности.

Заключение по первым экспериментам

На текущем этапе уже получен полноценный исследовательский результат:

- sparse FFN с top-k активациями обучаем;
- это верно и для короткого, и для более длинного контекста;
- это верно при разных уровнях спарсности;
- это верно при разных размерах модели;
- но наивная реализация через dense-backed masking системно неэффективна: она медленнее и требует больше памяти.

План дальнейшей работы по проекту:

1. Реализация efficient sparse FFN вместо naive torch + dense masking.
2. Реализация custom forward/backward kernels для sparse FFN.
3. Полное сравнение dense / naive sparse / optimized sparse.
4. Long-context scaling после kernel-оптимизации.
5. Финальная абляция по sparcity_ratio уже на optimized реализации.
6. Итоговый анализ trade-off между quality, throughput и peak memory.

(На каждый из пунктов потребуется около 4 дней, что укладывается в срок до защиты)